

尧泽斌

计算机科学与技术硕士研究生，南开大学

18107096525 | yaozb@nbjl.nankai.edu.cn | [GitHub](#) | [个人主页](#)

研究方向：向量检索、RAG、机器学习系统



EDUCATION

计算机科学与技术 | 硕士

南开大学 (NKU)

2023 年 9 月 | 至今

计算机科学与技术 | 本科

南开大学 (NKU)

2019 年 9 月 | 2023 年 6 月

GPA: 3.71/4.00

PUBLICATIONS

Demystifying and Enhancing the Efficiency of Large Language Model Based Search Agents.

[arXiv](#)

Annual Conference on Neural Information Processing Systems (ICLR), 2026.

(Under Review, 共同第一作者)

- 揭示了影响基于 LLM 的 Search Agent 效率的关键因素，并基于这些发现设计了 SearchAgent-X，以在不影响生成质量的前提下提高端到端效率。

Dynamic Detect and Fix Hardness for Efficient Approximate Nearest Neighbor Search.

Proceedings of the ACM SIGMOD International Conference on Management of Data (SIGMOD), 2026.

(第三作者)

- 提出了一种 ANN 图索引的新方法，通过引入“逃逸难度”来动态识别并修复有缺陷的图区域，以提升跨模态查询场景下近似最近邻搜索的性能。

ALGAS: A Low-latency GPU-Accelerated Approximate Nearest Neighbor Search System.

IEEE International Parallel & Distributed Processing Symposium (IPDPS), 2025.

(第三作者)

- 提出了一个用于小批量处理的低延迟 GPU 向量搜索系统，该系统通过动态批处理优化查询泡沫，利用 beam search 减少排序开销，以及 GPU-CPU 协作消除 TopK 合并开销，提高 GPU 资源利用率提升检索性能。

RESEARCH AND PROJECT EXPERIENCE

阿里巴巴集团

研究实习生

2024 年 10 月 | 2025 年 1 月

北京, 中国

- 索引优化：提出图索引修复算法，通过优化 ANN 图索引结构，解决了多模态图像检索中的长尾召回问题，显著提高了查询召回率，产出 SIGMOD 论文一篇。
- 并行算法：实现了基于多核 CPU 架构的查询内并行算法，加速大规模数据下的 ANN 搜索性能，性能超越 SOTA 方案。

Infinity

开源贡献者

[GitHub](#)

- 热门 AI 原生向量数据库项目，设计用于 LLM 应用，拥有 3.7k 个 stars，共贡献了几千行代码，成功合并到主分支。
- 向量索引存储：设计并实现了一种基于磁盘的向量索引架构，消除了分表复杂性，实现了高效的端到端索引构建与查询。

SELECTED AWARDS

公能奖学金，南开大学校奖

2024 年 9 月

公能奖学金，南开大学校奖

2023 年 9 月

教育部——华为智能基座奖学金

2022 年 10 月

创新与学业优秀奖学金，南开大学

2021 年 10 月